Probe-Gated Critic Transfer:
개인 보상 응답을 이용한 잠재 팀 발견

HwanRyul Lee

초록

같은 공간을 쓰는 에이전트라도 같은 목표를 갖는다고 할 수는 없다. 이 논문은 완전 분산 다중 팀 강화학습에서 온라인 잠재 팀 발견을 다룬다. 각 에이전트는 자기 관측과 자기 개인 보상만 보고, 팀 라벨은 주어지지 않으며, 물리적으로 접촉했을 때만 통신한다. 우리는 Probe-Gated Critic Transfer(PGCT)를 제안한다. 각 에이전트는 자기 보상을 예측하는 모델을 학습한다. 두 에이전트가 만나면 두 예측기가 공통 공개 보상 사건 probe, 즉 Reward Probe에 답하고, 여러 round에 걸쳐 평활한 정규화 응답 거리로 지속적인 일치를 승인한다. 보상 경험이 충분하지 않은 에이전트는 판정을 보류한다. 발견한 관계가 유용한지 확인하기 위해, 승인된 팀원의 Critic이 받는 에이전트 자신의 이력을 평가하고, 그 양의 상승분은 마스크와 크기 제한을 둔 Max-GAE advantage를 통해 Actor에만 들어간다. 모든 Critic은 계속 자기 return을 학습한다. 6 에이전트 · 2 팀 창고 과제에서 발견은 약 0.25M step부터 팀원을 구분하고(응답 거리 0.25 대 0.99), 5M step 동안 승인된 팀원 접근의 93.7%를 실제 팀원에게 보낸다. 통합 방법의 학습 비교는 진행 중이다.

1 서론

다중 에이전트 강화학습(MARL)의 협력 방법은 대개 협력할 집단을 미리 안다고 가정한다. 팀 공동 보상, 중앙 Critic, 파라미터 공유는 모두 어떤 에이전트끼리 한 팀인지 전제한다 [Yu et al., 2022, Christianos et al., 2021]. 실제로는 이 가정을 쓸 수 없는 경우가 많다. 한 창고 안에서 여러 로봇 팀이 각자의 요청 목록을 처리하고 각자의 목적지로 배송할 수 있다. 에이전트는 이웃을 볼 수 있지만, 가까이 있다는 사실만으로 그 이웃이 같은 과제를 하는지는 알 수 없다. 가치 정보를 무차별하게 공유하면 서로 다른 목표로 학습한 추정이 섞인다. 반대로 전혀 공유하지 않으면 이미 과제를 익힌 팀원의 도움을 받을 수 없다.

그래서 두 질문을 던진다. **Q1(발견):** 에이전트가 자기 경험과 국소 통신만으로 잠재 팀원을 온라인에서 찾을 수 있는가? **Q2(활용):** 팀원을 찾았을 때 그 가치 정보가 학습에 도움이 되는가? 이 논문의 중심은 Q1이다. Q2는 발견한 관계가 실제 학습에 쓸모 있는지 검증하는 역할을 한다.

Q1에 먼저 떠오르는 신호는 정책 유사도다. 하지만 같은 과제의 에이전트라도 학습 중에는 정책이 다를 수 있고, 다른 과제의 에이전트라도 둘 다 거의 무작위로 움직이면 비슷해 보인다. 우리는 과제를 정의하는 양, 즉 보상을 쓴다. 같은 팀의 에이전트는 같은 규칙으로 보상을 받으므로, 같은 사건은 두 에이전트 모두에게 보상이 된다. 다른 팀의 에이전트는 다른 사건에서 보상을 받는다. 각 에이전트는 보상 값을 공유하지 않고도 자기 보상으로 이 규칙을 학습할 수 있다. 그다음 두 에이전트는 공통 공개 사건에 대해 각자의 보상 예측기가 무엇이라고 답하는지 비교한다. 여기에는 세 가지 어려움이 있다. 보상 사건은 드물다. 관측에는 주고받으면 안 되는 과제 고유 채널이 있다. 그리고 보상 경험이 없는 에이전트는 비교할 보상 규칙 자체가 없다.

기여.

- 개인 보상, 팀 라벨 없음, 접촉으로 제한된 통신이라는 조건에서 완전 분산 다중 팀 MARL의 온라인 잠재 팀 발견 문제를 정의한다.
- 발견을 위한 보상 응답 Reward Probe 검정을 제안한다. 각 에이전트는 공개 전이에서 자기 보상을 예측하는 모델을 학습한다. 두 에이전트가 만나면 공통 보상 사건 probe에서 예측을 비교하고, 척도에 의존하지 않는 거리를 계산한다. 일치가 지속되면 승인하고, 자기 보상 증거가 부족한 에이전트는 판정을 보류한다. 비교에는 접촉 시점에 실제로 존재한 정보만 들어간다.
- 발견한 관계를 선택적 팀원 Critic 접근으로 활용한다. 승인된 팀원의 Critic이 받는 에이전트 자신의 이력을 평가하고, 그 양의 상승분이 마스크와 크기 제한을 둔 Max-GAE 항으로 Actor advantage를 바꾼다. 각 Critic은 자기 return만 목표로 하며, 승인된 팀원이 없으면 방법은 독립 PPO와 정확히 같아진다.
- 창고 과제에서 근거를 보고한다. 학습 중 발견 로그, 발견 규칙의 오프라인 재생, 전체 방법의 온라인 발견, 팀 관계가 팀원 가치에 왜 중요한지 보여 주는 반사실 점검이다.

2 관련 연구

독립 학습과 공유 학습. 독립 학습자는 자기 목표를 최적화하며, 협력 MARL에서도 여전히 강한 기준선이다 [Tan, 1993, de Witt et al., 2020, Papoudakis et al., 2021]. PPO와 일반화 advantage 추정(GAE)은 이런 학습자의 표준 구성요소다 [Schulman et al., 2017, 2016, Yu et al., 2022]. Shared Experience Actor-Critic은 협력하는 에이전트끼리 경험을 공유한다 [Christianos et al., 2020]. 선택적 파라미터 공유는 에이전트를 묶은 뒤 파라미터를 공유한다 [Christianos et al., 2021]. 완전 분산 actor-critic 방법은 네트워크로 연결된 에이전트가 공통 Critic에 합의하게 한다 [Zhang et al., 2018]. 이 방법들은 공통 목표를 가진 집단이 주어지거나, 모든 에이전트가 하나의 목표를 공유한다고 가정한다. PGCT는 개인 보상에서 집단을 추론하고, Actor와 Critic을 각자 따로 유지한다.

다른 에이전트 모델링. 에이전트 모델링은 다른 에이전트의 목표, 유형, 정책 같은 성질을 추론한다 [Albrecht and Stone, 2018]. Ad hoc 팀워크는 사전 조율 없이 모르는 팀원과 협력하는 문제를 다룬다 [Stone et al., 2010]. 우리가 추론하는 대상은 더 좁다. 다른 에이전트가 같은 규칙으로 보상받는지다. 추론에는 자기 보상 예측기와 공개 사건에 대한 상대의 예측만 쓰며, 상대 정책의 모델은 필요하지 않다.

여러 가치함수의 결합. 일반화 정책 개선은 여러 정책의 가치함수를 최댓값으로 결합한다 [Barreto et al., 2017]. MAMBA는 여러 oracle 가치의 상태별 최댓값을 GAE 형태의 추정기에 넣고, oracle 가치를 학습자의 상태 분포에서 추정할 때 개선 보장을 준다 [Cheng et al., 2020]. 우리의 Max-GAE 항은 이 결합 방식을 따른다. 그러나 전제는 성립하지 않는다. 팀원 Critic은 팀원 자신의 이력에서 학습되었고, 받는 에이전트의 이력에서 평가된다. rollout으로 다시 추정한 oracle 가치가 아니다. 따라서 성능 보장을 주장하지 않으며, 팀원 가치는 효과를 실험으로 측정해야 하는 Actor 보조 신호로 다룬다.

3 문제 설정

부분 관측 환경의 에이전트 N개를 생각한다. 에이전트 i는 관측 $o_{i,t}$를 받고 행동 $a_{i,t}$를 하며 자기 스칼라 보상 $r_{i,t}$를 받는다. 각 에이전트에는 숨은 팀 라벨 z_i가 있고, 같은 팀의 에이전트는 같은 규칙으로 보상받는다. $z_i = z_j$이면 두 에이전트를 잠재 팀원이라 한다. 라벨은 평가와 oracle 기준선에만 쓴다.

정보 모델. 각 에이전트는 자기 recurrent Actor와 Critic을 갖는다. 에이전트 i와 j는 rollout u 중 어느 step에서든 Chebyshev 거리 r_c 이내로 가까워졌을 때만 통신할 수 있다.

$$C^u_{ij} = \mathbf{1}[\exists t \text{ in rollout } u : \|p_{i,t} - p_{j,t}\|_\infty \le r_c], \qquad (1)$$
$$\mathcal{G}^u_i = \{j \neq i : C^u_{ij} B_{ij} = 1\}.$$

통신 반경은 관측 반경과 같게 둔다(이 과제에서 $r_c = 5$). 즉 에이전트는 자기가 볼 수 있는 에이전트와 통신한다. 보고한 실험의 반경은 6.1절에 적는다. 접촉했을 때 주고받을 수 있는 것은 공개 사건 view, 그 view에 대한 예측 보상, Critic 가중치다. 보상 값, 팀 라벨, Actor 가중치, 개인 궤적은 주고받지 않는다. 공개 투영 P는 과제 고유 관측 채널(요청 선반, 자기 팀 목적지)과 절대 좌표를 지운다. 구현에서 $P(o)$는 자기 상태 특징 6개와 반경 2 이내의 물리 격자 채널 11개를 남긴 281차원 view다. Actor와 Critic은 좌표 두 칸만 0으로 바꾼 전체 의미 관측을 쓴다.

목표. 각 에이전트는 만난 에이전트에 대해 관계 $\mathbf{1}[z_i = z_j]$를 추정하고, 증거가 부족하면 판정을 보류해야 한다. 그리고 자기 보상이나 Critic 목표를 바꾸지 않은 채 이 추정을 자기 학습 개선에 써야 한다.

4 Probe-Gated Critic Transfer

그림 1는 PGCT의 두 부분, 곧 팀 발견(위)과 선택적 Critic 활용(아래)을 보여 준다. 알고리즘 1는 update 한 번을 단계별로 적은 것이며, 1–4단계가 Q1, 5–7단계가 Q2에 해당한다.

4.1 개인 보상 예측

각 에이전트는 공개 전이 $q = (u_t, a_t, u_{t+1})$에서 자기 보상을 예측하는 다층 퍼셉트론을 학습한다.

$$\widehat{r}_i(q;\psi_i) = \mathrm{MLP}_{\psi_i}[u_t, \mathrm{onehot}(a_t), u_{t+1}], \quad u_t = P(o_{i,t}). \qquad (2)$$

입력은 $281+5+281 = 567$차원이고, 은닉층은 ReLU 128개와 64개다. 각 에이전트는 최근 전이 20,000개와, 이와 별도로 최근 보상 사건 512개를 저장한다. 사건은 자기 보상이 $r_i \ge 0.5$인 전이이며, 이 과제에서는 배송과 선반 반납이다. 사건은 전이의 0.5% 미만이므로, 학습 batch의 4분의 1을 사건 버퍼에서 뽑는다. 손실은 다음과 같다.

$$\mathcal{L}^r_i = \mathbb{E}_{(q,r_i)\sim\mathcal{B}^{\mathrm{mix}}_i}[(\widehat{r}_i(q;\psi_i) - r_i)^2]. \qquad (3)$$

예측기는 PPO update 5번마다 Adam으로 50 step 학습한다(batch 256, 학습률 10^{-3}). 공개 view는 과제 고유 정보를 숨기므로, 같은 공개 전이가 보상일 수도 아닐 수도 있다. 이때 회귀는 보상의 조건부 평균을 배우며, 비교하는 양이 바로 이것이다.

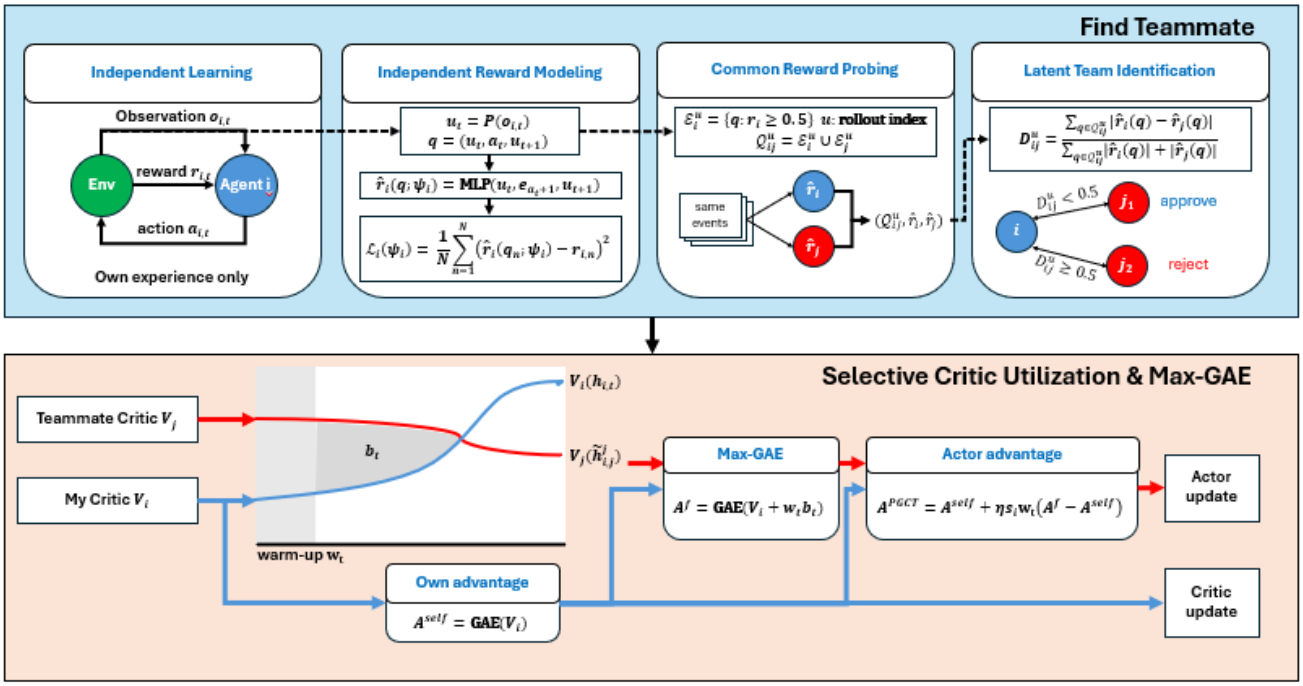


그림 1: 에이전트 i의 PGCT 전체 절차. 위: 에이전트는 자기 경험으로 학습하고, 공개 전이에서 보상 예측기를 맞추며, 만난 에이전트와 공통 보상 사건 probe에서 예측을 비교해 응답 거리가 작으면 승인한다(단순화한 그림이며 전체 규칙은 식 6). 아래: 승인된 팀원의 Critic이 GAE의 가치 입력을 양의 상승분 b_t만큼 올리고, 그 결과는 Actor update만 바꾼다. Critic은 계속 자기 return을 학습한다. 모든 계산은 국소적이며, 팀원끼리는 접촉했을 때만 공개 사건 view, 예측 응답, Critic 가중치를 주고받는다.

4.2 Reward Probe

rollout u 동안 i와 j가 만났다면, 두 에이전트는 다음 공통 probe 집합을 만든다.

$$\mathcal{Q}_{ij}^u = \mathcal{E}_i^u \cup \mathcal{E}_j^u. \tag{4}$$

$\mathcal{E}_i^u$는 rollout u가 시작되기 전에 기록된 에이전트 i의 최근 자기 사건 32개의 공개 view다. probe는 코드와 같이 중복을 허용해 이어 붙인다. 보상 값은 probe에 들어가지 않는다. 두 에이전트 모두 보상 사건을 겪었다면, 두 사건 집합에 이미 팀을 가르는 질문이 들어 있다. 한 목적지의 배송은 한 팀에게만 보상이다. 지도가 좌우 대칭임을 안다면, 선택적으로 좌우 대칭 사본 $M(\mathcal{E}_i^u \cup \mathcal{E}_j^u)$를 probe에 더할 수 있다. M은 view와 회전 행동을 좌우로 뒤집는다. 이는 지도에 대한 가정을 하나 더하므로 핵심 방법에는 넣지 않는다. 보고한 실험은 이 보강을 썼다(6.1절).

인과적 스냅샷. 비교는 rollout이 끝난 뒤 이루어지지만, 두 에이전트는 rollout 초반에 만났을 수도 있다. 접촉 시점에 존재한 정보만 쓰기 위해, 각 에이전트는 rollout u를 시작할 때 사건 probe, 성숙 여부, 예측기 버전을 고정한다. 예측기는 rollout이 끝난 뒤에만 다시 학습되므로, 고정된 버전이 곧 rollout 동안 쓰인 예측기다. rollout u의 비교는 이 고정본으로 하고, 예측기 재학습보다 먼저 수행한다.

4.3 응답 거리와 팀 발견

두 예측기는 같은 probe를 평가한다(그림 2). 응답 차이는 다음과 같다.

$$D_{ij}^u = \frac{\sum_{q\in\mathcal{Q}_{ij}^u} |\widehat{r}_i^u(q) - \widehat{r}_j^u(q)|}{\sum_{q\in\mathcal{Q}_{ij}^u} \left(|\widehat{r}_i^u(q)| + |\widehat{r}_j^u(q)|\right)}. \tag{5}$$

두 예측기가 모두 0이라고 답한 probe는 분자와 분모 어디에도 더해지지 않는다. 따라서 정보 없는 probe가 많아도 거리가 희석되지 않는다. 분모가 10^{-8}보다 작으면 비교를 보류한다. 에이전트는 자기 사건을 20개 이상 겪었고, 예측기가 학습되었으며, 자기 최근 사건에 대한 평균 예측이 0.3 이상일 때 성숙했다고 본다($m_i^u = 1$). 쌍은 5 update마다, 두 에이전트가 모두 성숙했을 때만 비교한다. 거리는 비교 round에 걸쳐 평활하고, 쌍은 다음 규칙으로 승인한다.

$$\bar{D}_{ij} \leftarrow (1-\beta)\bar{D}_{ij} + \beta D_{ij}^u, \quad \beta = 0.35, \tag{6}$$
$$B_{ij} = \mathbf{1}[i \neq j,\ n_{ij} \geq 3,\ \bar{D}_{ij} < 0.5,\ m_i^u = m_j^u = 1].$$

n_{ij}는 두 예측기가 모두 새 경험으로 다시 학습된 round의 수다. 승인은 대칭이며 접촉이 끊겨도 유지된다. 예전 승인은 두 에이전트가 다시 만났을 때만 쓰인다. 문턱 0.5는 응답 질량의 대부분이 겹친다는 뜻이며, 실험 결과에 맞춰 조정하지 않고 미리 정했다. 이 판정에는 팀 라벨이 쓰이지 않는다.

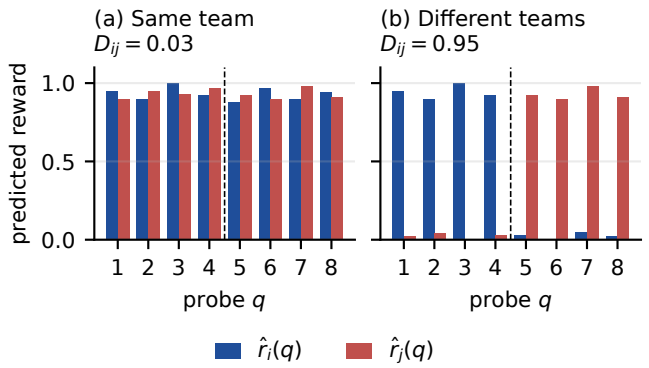


그림 2: 만난 두 에이전트의 보상 기반 팀 발견(설명용 예시이며 실험 데이터가 아니다). 두 보상 예측기가 공통 probe에 답한다. probe 1–4는 에이전트 i의 보상 사건, 5–8은 j의 보상 사건이다. (a) 같은 팀은 모든 probe에서 보상을 예측하므로 응답 거리가 0에 가깝다. (b) 다른 팀은 자기 사건에서만 보상을 예측하므로 거리가 1에 가깝다. 자기 보상 사건이 부족한 에이전트는 판정을 보류한다.

4.4 선택적 팀원 Critic 접근

rollout u에서 에이전트 i의 donor 집합은 다음과 같다.

$$\mathcal{G}_i^u = \{j \neq i : C_{ij}^u = 1,\ B_{ij} = 1\}. \tag{7}$$

donor Critic 가중치는 rollout u 동안 쓰인 가중치이며 접촉 시 전달받는다. update 동안에는 고정한다. 에이전트 i는 자기 관측 열을 각 donor Critic에 다시 넣어 donor별 recurrent 상태 $\tilde{h}_{i,t}^j$를 만든다. donor의 hidden 상태는 전달하지 않는다. 재생은 rollout 경계에서 0 상태로 시작하고 episode가 끝나면 초기화된다. 관측 8개가 지나거나 첫 초기화가 일어나기 전에는 재생 가치가 아직 믿을 만하지 않으므로, 마스크 $w_t = 0$으로 제외한다.

4.5 Max-GAE advantage 추정

donor 집합이 비어 있지 않으면 양의 상승분과 결합 가치는 다음과 같다.

$$b_{i,t} = \Big[\max_{j \in \mathcal{G}_i^u} V_j(\tilde{h}_{i,t}^j) - V_i(h_{i,t})\Big]_+, \tag{8}$$
$$f_{i,t} = V_i(h_{i,t}) + w_t b_{i,t}.$$

GAE 재귀는 trainer의 종료와 시간 제한 처리를 그대로 따른다.

$$\delta_{i,t}^f = r_{i,t} + \gamma(1-d_t) f_{i,t+1} + \gamma z_{i,t}^f - f_{i,t}, \tag{9}$$
$$A_{i,t}^f = \delta_{i,t}^f + \gamma\lambda_f(1-d_t)A_{i,t+1}^f.$$

d_t는 episode 종료 표시이고, $z_{i,t}^f$는 시간 제한으로 끝난 관측의 가치다(그 밖에는 0). 자기 advantage A^{self}는 f 대신 V_i로 같은 재귀를 계산한다. $\gamma = 0.99$, $\lambda_f = \lambda = 0.95$일 때 Actor advantage는 다음과 같다.

$$A_{i,t}^{\text{PGCT}} = A_{i,t}^{\text{self}} + \eta\, s_i\, w_t\big(A_{i,t}^f - A_{i,t}^{\text{self}}\big), \qquad \eta = 0.5, \tag{10}$$
$$s_i = \min\left(1, \frac{\text{std}_t\, A_{i,t}^{\text{self}}}{\max\big(\text{std}_t\ w_t(A_{i,t}^f - A_{i,t}^{\text{self}}),\ 10^{-8}\big)}\right).$$

그림 1의 아래쪽이 이 계산을 보여 준다. 두 가지가 중요하다. 첫째, 마스크 w_t는 b만이 아니라 advantage 차이 $A^f - A^{\text{self}}$에 곱한다. b만 가리면 미래 상승분이 GAE 재귀를 통해 초기 구간으로 새어 들어온다. 둘째, 계수 $s_i \leq 1$은 큰 보조 항을 자기 advantage 크기로 줄이지만, 작은 항을 키우지는 않는다. 이 과제에서 뒤처진 에이전트의 원래 차이는 std A^{self}의 2.6–12배였다. s_i가 없으면 PPO의 advantage 정규화 때문에 결과가 η와 거의 무관해진다.

알고리즘 1 에이전트 i의 PGCT update 한 번

1: rollout 시작 시 사건 probe, 성숙 여부, 예측기 버전을 고정한다.
2: rollout을 모으고, 자기 공개 전이와 자기 사건을 저장하며, 접촉 C_{ij}^u를 기록한다.
3: **if** update 번호가 5의 배수 **then**
4: 접촉한 성숙 쌍을 고정 probe로 비교하고 $\bar{D}_{ij}$, n_{ij}를 갱신한다(식 5–6).
5: 자기 경험으로 보상 예측기를 다시 학습한다(식 3).
6: **end if**
7: donor: 이번 rollout에서 만난 승인 팀원(식 7).
8: 자기 이력을 donor Critic에 재생하고 b, f, A^{PGCT}를 계산한다(식 8–10).
9: Actor는 A^{PGCT}로 PPO update, Critic은 자기 return으로 update한다(식 11).

4.6 Actor와 Critic update

에이전트별 정규화를 거친 Actor advantage를 $\widetilde{A}_{i,t}$라 쓰자. PPO는 다음을 쓴다.

$$\rho_{i,t}(\theta_i) = \pi_{\theta_i}(a_{i,t} \mid h_{i,t}) / \pi_{\theta_i^{\text{old}}}(a_{i,t} \mid h_{i,t}), \tag{11}$$
$$L_i^\pi = \mathbb{E}_t[\min\{\rho_{i,t}\widetilde{A}_{i,t}, \text{clip}(\rho_{i,t}, 1-\epsilon, 1+\epsilon)\widetilde{A}_{i,t}\}],$$
$$R_{i,t}^{\text{self}} = A_{i,t}^{\text{self}} + V_i^{\text{old}}(h_{i,t}).$$

Actor는 clip된 목적함수에 엔트로피 보너스를 더해 최대화한다. Critic은 자기 return R^{self}를 향한 trainer의 clip된 가치 손실을 최소화하며, 팀원 증류 손실은 없다. Actor와 Critic은 encoder와 recurrent 층을 따로 쓴다. 다만 gradient norm clip 하나를 함께 쓰므로, Actor advantage가 달라지면 Critic의 실제 step 크기는 달라질 수 있다. 목표는 바뀌지 않는다.

5 성질

범위가 정해진, 척도 무관 거리. 삼각부등식에 의해 분모가 양수이면 $D^u_{ij} \in [0,1]$이다. 두 예측기에 공통인 보상 척도에 거리가 의존하지 않는다.

발견의 필요조건. 두 보상 규칙이 에이전트가 쓸 수 있는 모든 공개 probe에서 같은 예측 응답을 만든다면, 이 응답만 보는 어떤 규칙도 둘을 구분할 수 없다. 따라서 발견에는 과제를 구분하는 공개 보상 사건이 필요하다. 자격 있는 보상을 한 번도 받지 못한 에이전트는 비교할 응답이 없으며, PGCT는 설계상 그 에이전트에 대해 판정을 보류한다.

독립 PPO로의 환원. $\mathcal{G}^u_i = \emptyset$이거나 모든 t에서 $b_{i,t} = 0$이면 $A^f = A^{\text{self}}$이므로 $A^{\text{PGCT}} = A^{\text{self}}$다. $s_i \le 1$이므로 상승분이 0으로 가면 $|A^{\text{PGCT}} - A^{\text{self}}|$도 0으로 간다. donor 집합, 마스크 밖 step, s_i가 고정되면 GAE는 가치 입력에 대해 선형이고, Actor advantage는 $V_i + \eta s_i w_t b_i$로 계산한 GAE와 같다.

가치 오차에 대한 민감도. 계속되는 궤적에서 유계 가치 섭동 Δf에 대해 다음이 성립한다.

$$\|\Delta A\|_\infty \le \left(1 + \frac{\gamma(1-\lambda)}{1-\gamma\lambda}\right) \|\Delta f\|_\infty. \tag{12}$$

이는 팀원 가치 오차가 advantage를 얼마나 움직일 수 있는지에 대한 상한이며 성능 보장이 아니다. 팀원 가치는 다른 에이전트의 이력으로 외삽되고, 다른 에이전트들은 계속 학습하며, 접촉은 rollout마다 바뀐다.

6 실험

6.1 설정

환경. 로봇 창고 환경 [Papoudakis et al., 2021]의 다중 팀 변형을 쓴다. 11×10 격자에 에이전트 6개가 3개씩 두 팀으로 나뉜다. 팀 목적지는 아래쪽 두 모서리 $(0,10)$과 $(9,10)$이다. 팀마다 요청 선반이 3개 있다. 관측은 감지 반경 5의 의미 격자다. 모든 에이전트는 자기 보상을 받는다. 배송 1, 선반 반납 1, 요청 선반 집기 0.15, 작은 진척 항(0.02, 0.005, 0.002), 비생산적 행동에 대한 작은 감점(0.002–0.05)이다. 팀 보상은 쓰지 않는다. 표 1에 학습 설정을 정리했다. 보고한 실험은 기본 방법과 두 설정이 다르다. 접촉 반경으로 관측 반경보다 작은 $r_c = 3$을 썼고, probe에 좌우 대칭 사본을 더했다. 반경 3 안의 접촉은 반경 5 안의 접촉이기도 하므로, 기본 설정은 접촉을 더할 뿐이다. 대칭 사본을 뺀 오프라인 재생은 같은 판정을 냈다(6.2절). $r_c = 5$와 대칭 사본 없는 실험은 진행 예정이다.

설정	값
rollout / recurrent 길이	1024 / 64 step
PPO epoch / minibatch	4 / 8
학습률 / 엔트로피	2×10^{-4} / 0.05
PPO clip / 가치 clip	0.2 / 0.2
할인율 / GAE 계수	0.99 / 0.95
encoder / GRU 폭	128 / 128
보상 학습 간격 / step	5 update / 50
사건 기준 / 성숙	$r \ge 0.5$ / 사건 20개
EMA β / 문턱 / round	0.35 / 0.5 / 3
실험의 접촉 반경 r_c(Chebyshev)	3
실험의 좌우 대칭 probe	사용
Max-GAE η / 척도	0.5 / shrink

표 1: 환경 상호작용과 PGCT 설정.

분기 실험. 전체 방법을 온라인으로 실행하기 위해 1.024M step의 공통 독립 PPO checkpoint(seed 1)에서 분기해 0.5M step을 더 학습한다. seed는 checkpoint의 목적지 배치를 유지하는 1, 3, 5를 쓴다. 이 checkpoint에서 세 에이전트(a_0, a_1, a_4)는 배송이 거의 없거나 전혀 없다. 대조군으로, 같은 분기에서 성숙한 에이전트로 제한한 실제 팀원을 donor로 쓰는 학습도 돌렸고, 이 학습도 같은 발견 통계를 기록한다. 분기 seed는 하나의 학습을 이어 간 것이므로 독립 학습 seed가 아니다.

6.2 팀 발견

그림 3는 PGCT의 발견 규칙이 작동한 5M step 학습(seed 1)이다. 에이전트가 성숙하자마자 같은 팀과 다른 팀 쌍이 갈린다. 0.1–0.25M 구간에서 평균 응답 거리는 팀원 0.25, 그 밖 0.99이고, 0.25M까지 6개 중 5개 에이전트가 성숙했다. 같은 팀 거리는 계속 내려간다(4M 이후 0.08). 다른 팀 거리는 약 1M까지 0.99 근처에 머문 뒤 천천히 내려간다. 학습 전체에서 방향 있는 팀원 접근 arc 5,252개가 실제 팀원에게, 352개가 다른 팀에게 향했으며, 같은 팀 비율은 93.7%다. 첫 다른 팀 승인은 4.28M step에 나타나므로, 그 전의 접근은 모두 맞았다. 이 비율은 접근 빈도로 가중한 값이며 쌍 단위 정확도가 아니다. 이 학습은 update 종료 시점의 위치를 접촉으로 썼고 이전의 팀원 활용 규칙을 썼으므로, 발견 구성요소만 평가한다.

오프라인 점검으로, 완료된 독립 PPO 학습의 경험 일부(0.26–5M step, 전이의 약 1/180)를 같은 규칙에 재생했다. 모든 쌍이 매 round 접촉한다고 가정했다. 15쌍 가운데 판정에 이른 10쌍은 모두 맞게 분류되었다. 같은 팀 승인 4쌍, 다른 팀 승인 0쌍이다(같은 팀 거리 0.14–0.18, 다른 팀 0.58–0.70). 나머지 5쌍은 모두 배송을 끝내 배우지 못한 한 에이전트가 낀 쌍이었고, 판정을 보류했다. 이 재생에서 좌우 대칭 probe를 빼도 모든 판정이 같았다.

분기 실험(6.1절)은 rollout 시작 스냅샷과 접촉 규칙을 포함한 전체 방법을 온라인으로 실행한다. PGCT 분기 세 개(seed 1, 3, 5; seed 5는 0.5M 중 0.46M까지)에서 다른

팀 쌍은 한 번도 승인되지 않았고, Max-GAE가 쓴 donor arc는 모두 실제 팀원을 향했다(1,920, 1,350, 1,258개). 첫 승인은 분기 후 20k–26k step에 나왔다. 각 학습에서 네 에이전트가 성숙했다. 한 팀의 세 에이전트 전부와 다른 팀의 한 에이전트다. PGCT는 첫 팀 안의 방향 있는 arc 6개를 모두 승인했고, 혼자 성숙한 에이전트와 그 팀 사이의 arc 6개는 하나도 승인하지 않았다. 따라서 같은 팀 arc 12개 중 6개를 찾았고 나머지는 판정을 보류했다. 대조군 세 학습의 발견 통계에도 다른 팀 승인은 없다. 이 분기는 학습 1.02–1.52M step 구간으로, 5M 학습 후반에 보인 다른 팀 거리 하락보다 앞선다.

6.3 팀 관계가 팀원 가치에 중요한 이유

팀원의 Critic은 팀원에게만 쓸모 있을까? 저장된 독립 PPO checkpoint로 반사실 점검을 했다. 같은 환경 상태에서 뒤처진 에이전트를 자기 정책으로, 또는 다른 에이전트의 정책으로 움직이게 했다. 나머지 에이전트는 자기 정책을 유지했다. 그리고 100 step 동안 뒤처진 에이전트 자신의 return을 비교했다(공통 난수, 8회 반복). 네 checkpoint 데이터(한 학습의 두 시점, 좌표가 보이는 이전 설정의 두 학습)에서, 같은 팀 Critic이 뒤처진 에이전트에 대해 0.2보다 큰 상승을 예측했을 때 그 팀원의 정책은 실제로 에이전트의 return을 67–100%의 경우에 높였다(평균 이득 0.28–0.58). 비슷한 크기의 다른 팀 상승은 평균 이득이 -0.01–0.14에 그쳤다. 앞선 에이전트에게는 다른 팀 Critic이 상승을 예측하는 경우가 많았지만, 실제로는 유의한 손실이 따르기도 했다. 예측 상승은 실제 이득을 최대 1.6배까지 과대평가했다. 이 관찰은 발견 단계와 상승분의 보수적 축소가 모두 필요하다는 근거다.

7 한계

발견은 보상 경험에 의존한다. 자격 있는 보상을 한 번도 받지 못한 에이전트는 짝지을 수 없고, 그 에이전트가 바로 도움이 가장 필요한 에이전트일 수 있다. PGCT 분기 실험에서 뒤처진 세 에이전트 가운데 둘(a_0, a_4)은 끝내 성숙하지 않아 PGCT가 판정을 보류했다. 5M 학습 후반에는 다른 팀 거리가 내려가고 다른 팀 승인이 일부 나타났으며, 원인은 아직 분석하지 않았다. 팀원 Critic은 팀원 자신의 정책에서 return을 추정하므로, 다른 에이전트의 이력에서 계산한 값은 편향될 수 있고 최댓값이 그 편향을 키울 수 있다. 선택적 Critic 활용이 학습을 빠르게 하는지는 아직 보이지 않았고, 현재 근거는 한 환경 계열과 적은 seed에서 나왔다.

8 결론

PGCT는 개인 보상 응답으로 잠재 팀원을 온라인에서 찾는다. 각 에이전트는 자기 보상을 예측하고, 만난 팀원과 공개 보상 사건 probe에서 예측을 비교하며, 충분한 자기 경험으로 뒷받침되는 지속적 일치만 승인한다. 발견한 관계는 보수적으로 쓴다. 승인된 팀원의 Critic이 마스크와 크기 제한을 둔 Max-GAE 항으로 Actor advantage를 바꾸고, 각 Critic은 자기 return을 유지한다. 두 팀 창고 과제에서 발견은 이른 시점에 팀원을 구분하고 팀원 접근의 대부분을 실제 팀원에게 보내며, 전체 방법의 분기 실험에서는 다른 팀 쌍을 한 번도 승인하지 않았다. 이 접근이 학습을 빠르게 하는지는 아직 검증 중이다.

참고문헌

Stefano V. Albrecht and Peter Stone. Autonomous agents modelling other agents: A comprehensive survey and open problems. *Artificial Intelligence*, 258:66–95, 2018. URL https://doi.org/10.1016/j.artint.2018.01.002.

André Barreto, Will Dabney, Rémi Munos, Jonathan J. Hunt, Tom Schaul, Hado van Hasselt, and David Silver. Successor features for transfer in reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

Ching-An Cheng, Andrey Kolobov, and Alekh Agarwal. Policy improvement via imitation of multiple oracles. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL https://proceedings.neurips.cc/paper/2020/hash/3c56fe2f24038c4d22b9eb0aca78f590-Abstract.html.

Filippos Christianos, Lukas Schäfer, and Stefano V. Albrecht. Shared experience actor-critic for multi-agent reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL https://proceedings.neurips.cc/paper/2020/hash/7967cc8e3ab559e68cc944c44b1cf3e8-Abstract.html.

Filippos Christianos, Georgios Papoudakis, Arrasy Rahman, and Stefano V. Albrecht. Scaling multi-agent reinforcement learning with selective parameter sharing. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, 2021. URL https://proceedings.mlr.press/v139/christianos21a.html.

Christian Schroeder de Witt, Tarun Gupta, Denys Makoviichuk, Viktor Makoviychuk, Philip H. S. Torr, Mingfei Sun, and Shimon Whiteson. Is independent learning all you need in the StarCraft multi-agent challenge? *arXiv preprint arXiv:2011.09533*, 2020.

Georgios Papoudakis, Filippos Christianos, Lukas Schäfer, and Stefano V. Albrecht. Benchmarking multi-agent deep

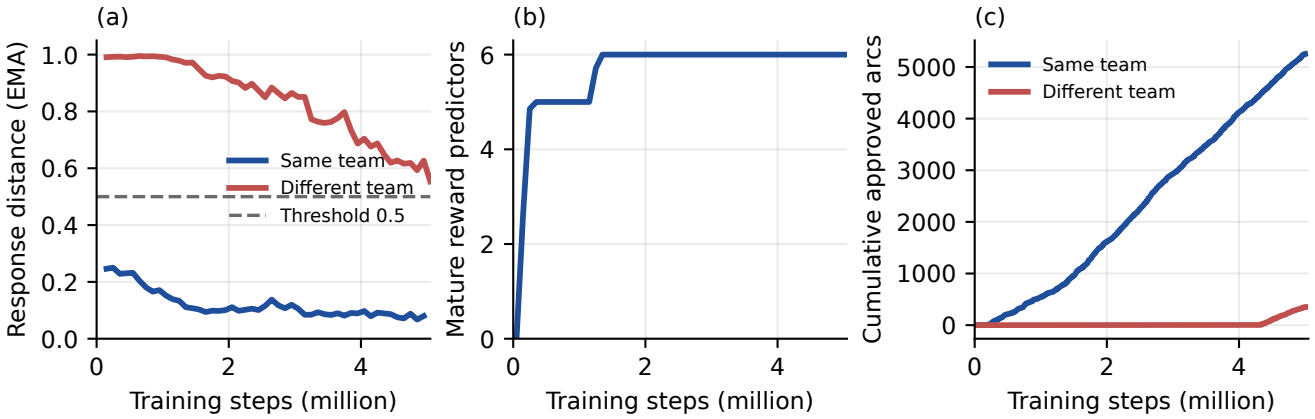


그림 3: 창고 과제의 팀 발견(모서리 목적지, 개인 보상, seed 1, 5M step). (a) 비교한 쌍의 응답 거리 EMA 평균, 100k step 구간. 점선은 승인 문턱이다. (b) 보상 예측기가 성숙한 에이전트 수. (c) 실제 관계별 방향 있는 팀원 접근 arc 누적.

reinforcement learning algorithms in cooperative tasks. In *NeurIPS Datasets and Benchmarks*, 2021. URL https://arxiv.org/abs/2006.07869.

John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations*, 2016. URL https://arxiv.org/abs/1506.02438.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. URL https://arxiv.org/abs/1707.06347.

Peter Stone, Gal A. Kaminka, Sarit Kraus, and Jeffrey S. Rosenschein. Ad hoc autonomous agent teams: Collaboration without pre-coordination. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 24, 2010.

Ming Tan. Multi-agent reinforcement learning: Independent vs. cooperative agents. In *Proceedings of the Tenth International Conference on Machine Learning*, pages 330–337, 1993.

Chao Yu, Akash Velu, Eugene Vinitsky, Jiaxuan Gao, Yu Wang, Alexandre Bayen, and Yi Wu. The surprising effectiveness of PPO in cooperative multi-agent games. In *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*, volume 35, 2022.

Kaiqing Zhang, Zhuoran Yang, Han Liu, Tong Zhang, and Tamer Başar. Fully decentralized multi-agent reinforcement learning with networked agents. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 5872–5881, 2018.

A 구현 세부

발견 상태의 일관성을 검사한다. rollout 시작 스냅샷과 비교 사이에 예측기가 다시 학습되면 오류로 처리한다. 승인은 저장된 round와 EMA 값에서 다시 구성하며, 현재 성숙 표시와 대조한다. 자기 rollout에서 explained variance가 문턱보다 낮은 donor Critic을 제외하는 선택 필터가 있지만, 문턱을 정하지 않았으므로 꺼 두었다. donor 집합은 update 한 번 동안 고정된다. 자기 return 목표는 Actor advantage를 만들기 전에 계산한다.

근거 자료: 발견 로그는 `runs/acv2_s1_20261029_084340`, 분기 실험은 `runs/pgctd2_br1M_20261102_180212`(W&B 요약: `output/branch_wandb_20261104`)이다. 그림 3은 원본 로그에서 `output/pgct_docs_20261102/evidence_plots.py`로, 그림 2는 `output/pgct_docs_20261102/discovery_illustration.py`로 다시 만든다.